Compte Rendu MN-TP2 Blas

2
2
2
3
3
4
5
6
7
8
9

Fonctions BLAS:

En utilisant des boucles for, nous avons implémenté les fonctions de blas 1, blas 2 et blas 3. Ces fonctions nous permet de faire des calculs avec des vecteurs de nombres flottants, mais aussi avec des vecteurs de nombre complexes (avec leur partie réel et imaginaire) ainsi qu'avec des matrices (dans blas 2 et 3). Les différents type des fonctions sont représenté par une lettre.

S	Type flottant à précision simple
D	Type flottant à précision double
С	Type complexe à précision simple
Z	Type complexe à précision double

Type complexe

```
typedef struct c{
    float real;
    float imaginary;
} complexe_float_t;

typedef struct z{
    double real;
    double imaginary;
} complexe_double_t;
```

Figure 0: Implémentation des types complexes

Nous avons implémenté nos types complexes avec des structures possédant deux variables, la partie réel et la partie imaginaire du nombre complexe. Nous avons ensuite créé 4 fonctions pour ces deux types permettant d'additionner deux nombres complexes, de multiplier deux nombres complexes, de conjuguer un nombre complexe et enfin de comparer deux nombres complexe.

Blas 1

Les fonctions **dot** calcule la somme des vecteurs X*Y.

Les fonctions **copy** réalisent une copie de X dans Y.

Les fonctions **axpy** permettent de calculer Y = Y + alpha*X, avec alpha étant une constante.

Les fonctions **iamin** renvoient l'indice où se situe l'élément qui a la plus petite valeur absolue de X.

Les fonctions **iamax** renvoient l'indice où se situe l'élément qui a la plus grande valeur absolue de X .

Les fonctions **swap** inversent les éléments de 2 vecteurs X et Y.

Les fonctions **asum** calculent la somme des valeures absolues des éléments d'un vecteur.

Les fonctions **nrm2** calculent la norme du vecteur X.

Blas 2

Les fonctions **gemv** prennent en paramètre 3 structures : deux vecteurs X et Y, et une matrice A. On a également besoin de deux constantes alpha et beta. La fonction réalise ensuite le calcul suivant :

$$Y = alpha*A*X + beta*Y$$

Pour réaliser facilement cette fonction on utilise la fonction dot de BLAS 1. Pour cette fonction on considère que la matrice est stocké par colonnes (donc on ne fait pas attention au paramètre layout). De plus on ne traite que le cas où la matrice est normal, soit non transposée.

Blas 3

Les fonctions **gemm** prennent en paramètre 3 matrices A, B et C ainsi que deux constantes alpha et beta. Avec ces paramètres, la fonction réalise le calcul suivant:

$$C = alpha*A*B + beta*C$$

Pour réaliser facilement cette fonction on utilise aussi la fonction dot de BLAS 1. Et on ne realise que les mêmes cas que gemv.

Performances

Nous avons testé les performances de toutes nos fonctions blas, en GFLOP(s) ou en GO/s. De plus, nous comparons nos performances calculé avec celle du blas réalisé par Intel. Tous nos programmes de performances se trouvent dans le dossier example du tp. Pour les utiliser il faut avoir la librairie cblas.h.

Pour la compilation de nos programmes BLAS, nous avons expérimenté avec les options de compilation de GCC -O1, -O2 et -O3, permettant d'optimiser le code. Nous avons décidé de garder l'option -O3 qui est sensé optimiser le mieux possible nos programmes.

Lors de la réalisation de nos tests de performances, nous avons remarqué plusieurs choses commune à tous les programmes.

- Les premiers tests sont souvent les plus lents (et donc possèdent les GFLOPS ou GO/s les plus faible), nous pensons que cela vient du faites que les données ne sont pas encore en cache et donc que l'accès mémoire fait perdre de la vitesse.
- Nos programmes sont majoritairement tous moins performant que ceux réalisé par Intel. Nous avons des hypothèses sur cela, soit cela doit venir du faites que leur programmes sont mieux implémenté que les notres (ce qui est fort probable), soit que leur programmes utilise du multi-threading permettant de grandement accélérer l'exécution (ce qui est pratiquement sûre) ou enfin que leur programme utilise directement le hardware du processeur pour certaine fonction.
- Les résultats des performances obtenue ne sont pas les mêmes que les résultats que l'on pensait recevoir. Le plus fréquemment les performances de nos fonctions non complexe était meilleur que nos performance sur des fonctions utilisant des complexes. Nous pensions que les fonctions utilisant des nombres complexe serait plus performantes car réalisant le plus d'opération simple et donc rapide à réaliser. Ou alors que les performances entre non complexes et complexes soient relativement similaire.

Performance de dot

```
NCBLAS:
 Fonction sdot :
262144 nombre total d'operations
1161322 nombre total de cycles
0.587 GFLOP/s
 Fonction ddot :
262144 nombre total d'operations
1163100 nombre total de cycles
0.586 GFLOP/s
 onction cdotu_sub :
                1048576 nombre total d'operations
8737115 nombre total de cycles
0.312 GFLOP/s
 Fonction cdotc_sub :

1179648 nombre total d'operations

7856402 nombre total de cycles

0.390 GFLOP/s
Fonction zdotu_sub :
                1048576 nombre total d'operations
7244591 nombre total de cycles
                0.376 GFLOP/s
Fonction zdotc_sub :
1179648 nombre total d'operations
7338465 nombre total de cycles
0.418 GFLOP/s
 CBLAS:
Fonction sdot :
               262144 nombre total d'operations
140264 nombre total de cycles
4.859 GFLOP/s
Fonction ddot :

262144 nombre total d'operations
340845 nombre total de cycles
2.000 GFLOP/s
 onction cdotu_sub :
                1048576 nombre total d'operations
402855 nombre total de cycles
6.767 GFLOP/s
 Fonction cdotc_sub :

1179648 nombre total d'operations

383113 nombre total de cycles

8.006 GFLOP/s
 Fonction zdotu_sub :

1048576 nombre total d'operations

406374 nombre total de cycles

6.709 GFLOP/s
Fonction zdotc_sub :

1179648 nombre total d'operations

403766 nombre total de cycles

7.596 GFLOP/s
```

Figure 1: Performances des fonctions dot

On remarque dans un premier temps que nos fonctions blas sont moins performantes que celles écrites par Intel. Nos fonctions sont moins optimisés, donc plus lentes. Cette tendance se retrouve dans toutes les autres fonctions de ce TP. Concernant les fonctions en elle même, on voit que les fonctions dans les nombre réels sont globalement plus performante que les fonctions traitant les nombres complexes. Dans celles ci, calculer le conjugué d'un nombre complexe ralentit encore plus le programme. On remarque que nos fonctions on tendance a être plus rapide en travaillant avec des doubles plutôt qu'avec des flottants.

Performance de copy

```
MNCBLAS:
Fonction scopy:

8388608 nombre total d'octets
5572495 nombre total de cycles
3.914 Goctet(s)/s

Fonction dcopy:

16777216 nombre total d'octets
3732746 nombre total de cycles
11.686 Goctet(s)/s

Fonction ccopy:

33554432 nombre total d'octets
4000433 nombre total de cycles
21.808 Goctet(s)/s

Fonction zcopy:

67108864 nombre total d'octets
8111258 nombre total de cycles
21.511 Goctet(s)/s

CBLAS:
Fonction scopy:

8388608 nombre total de cycles
6.771 Goctet(s)/s

Fonction dcopy:
16777216 nombre total d'octets
3135935 nombre total de cycles
13.910 Goctet(s)/s

Fonction ccopy:
33554432 nombre total de cycles
13.910 Goctet(s)/s

Fonction ccopy:
33554432 nombre total de cycles
13.688 Goctet(s)/s

Fonction zcopy:
67108864 nombre total d'octets
5088505 nombre total de cycles
34.290 Goctet(s)/s
```

Figure 2: Performances des fonctions copy

Les fonctions copy sont un peu particulières. On ne peut pas calculer de performance en GFLOP/s car il n'y a pas d'opérations flottantes dans ces fonctions. On calcule donc les performances autrement, avec le nombre d'octets par secondes. Ici on a une tendance inverse. Les opérations avec les doubles sont encore plus rapides, mais les complexes sont plus rapide que les nombres non-complexes. Cela est dû au fait que des informations sont stockées dans le cache. L'accès en mémoire est donc plus rapide. On remarque également que notre fonction ccopy est plus rapide que celle écrite par Intel, cela vient peut être de l'optimisation à la compilation (-O3) qui peut être fait des approximations ou garde des valeurs en cache ou alors juste du cache du processeur étant plus utilisé dans un cas que dans l'autre.

Performance de axpy

```
MNCBLAS:
Fonction saxpy:

1048576 nombre total d'operations
3123606 nombre total de cycles
0.873 GFLOP/s

Fonction daxpy:

1048576 nombre total d'operations
1244641 nombre total de cycles
2.190 GFLOP/s

Fonction caxpy:

4194304 nombre total d'operations
29676679 nombre total de cycles
0.367 GFLOP/s

Fonction zaxpy:

4194304 nombre total d'operations
28874507 nombre total de cycles
0.378 GFLOP/s

CBLAS:
Fonction saxpy:

1048576 nombre total d'operations
227793 nombre total de cycles
11.968 GFLOP/s

Fonction daxpy:
1048576 nombre total d'operations
748587 nombre total de cycles
3.642 GFLOP/s

Fonction caxpy:
4194304 nombre total d'operations
2725483 nombre total de cycles
4.001 GFLOP/s

Fonction zaxpy:
4194304 nombre total d'operations
89110794 nombre total de cycles
0.122 GFLOP/s
```

Figure 3: Performances des fonctions axpy

Pour axpy, on voit que d'abord que les nombres complexes sont plus lent dans nos fonctions. Les doubles sont plus rapides ques les flottants. La fonction daxpy est plus rapide que les autres. En comparant avec les fonctions d'Intel, on remarque quelques différences. Leurs fonctions utilisant les doubles sont plus lentes que leurs fonctions utilisant les flottants, tandis que nos fonctions suivent la tendance inverse. Cela peut s'expliquer par une différence d'implémentation, on un manque d'optimisation.

Performance de gemv

Figure 4: Performances des fonctions gemv

On remarque dans un premier temps que sgemv est plus rapide que dgemv, ce qui est logique. Par contre, zgemv est plus rapide que cgemv, alors que cela devrait normalement être l'inverse. Pour les fonctions d'Intel, on voit que cgemv est la fonction la plus rapide, contrairement à nous où elle est le plus lente.

Performance de gemm

Figure 5: Performances des fonctions gemm

Nos fonctions gemm sont plus rapide en calculant avec des doubles, et les fonctions complexes sont bien plus lentes. Le seul élément remarquable est que notre fonction dgemm est anormalement rapide comparée à la fonction d'Intel. Cela est peut être dû au fait que l'on n'a pas implémenté toutes les fonctionnalitées proposées dans la fonction par Intel.